

Análise comparativa de conversores de dados tabulares em imagem para classificação de genes diferencialmente expressos em CNNs

André Hübner
Instituto de Informática – UFRGS
Porto Alegre, RS, Brazil
andrehubner70@gmail.com

Douglas Nascimento
Instituto de Informática – UFRGS
Porto Alegre, RS, Brazil
doug@inf.ufrgs.br

Eduardo Abdala
Instituto de Informática – UFRGS
Porto Alegre, RS, Brazil
esabdala@inf.ufrgs.br

27 de junho de 2026

Abstract. Convolutional neural networks (CNNs) are highly effective for images, but their direct application to tabular RNA-seq data is limited by the absence of natural spatial structure among features. This work presents a comparative pipeline for converting gene-centered tabular representations into images and classifying genes as upregulated, downregulated or not differentially expressed. RNA-seq count matrices from TCGA-LUAD, TCGA-KIRC and TCGA-PRAD were processed with DESeq2 to derive differential-expression features, converted into images using DeepInsight, NCTD and HACNet, and evaluated with a ResNet18-based classifier. Traditional machine learning models were also trained directly on the original tables, and Gene Ontology enrichment was used as a biological validation layer. The proposed workflow integrates predictive evaluation and functional analysis to assess whether table-to-image representations can preserve useful information for the classification of differentially expressed genes.

Resumo. Redes neurais convolucionais (CNNs) apresentam alto desempenho em imagens, mas sua aplicação direta a dados tabulares de RNA-seq é limitada pela ausência de uma estrutura espacial natural entre as características. Este trabalho apresenta um pipeline comparativo para converter representações tabulares centradas em genes em imagens e classificar genes como regulados positivamente, regulados negativamente ou não diferencialmente expressos. Matrizes de contagem de RNA-seq dos projetos TCGA-LUAD, TCGA-KIRC e TCGA-PRAD foram processadas com DESeq2 para a obtenção de características de expressão diferencial, convertidas em imagens por DeepInsight, NCTD e HACNet e avaliadas com um classificador baseado em ResNet18. Modelos tradicionais de aprendizado de máquina também foram treinados diretamente sobre as tabelas originais, e enriquecimento de Gene Ontology foi utilizado como camada de validação biológica. O fluxo proposto integra avaliação preditiva e análise funcional para investigar se representações T2I preservam informação útil para classificação de genes diferencialmente expressos.

Keywords: Conversão Tabela-para-Imagem, CNN, Expressão Diferencial, RNA-seq, TCGA

1 Introdução

Redes neurais convolucionais (CNNs) constituem uma das principais classes de modelos de aprendizado profundo aplicadas a dados organizados em grades, especialmente imagens. Sua eficiência decorre da exploração de padrões locais por filtros convolucionais compartilhados, permitindo que estruturas espaciais

sejam progressivamente combinadas em representações mais abstratas [1]. Essa propriedade, no entanto, não se transfere automaticamente para dados tabulares, nos quais cada coluna representa uma variável distinta e a proximidade entre colunas não possui, necessariamente, significado espacial ou biológico.

Dados de RNA-seq são um exemplo particularmente relevante desse desafio. Em estudos de câncer, a comparação entre amostras tumorais e normais permite identificar genes diferencialmente expressos (DEGs), que podem indicar processos biológicos alterados, potenciais biomarcadores e vias associadas à tumorigênese [2]. A análise estatística de DEGs é tradicionalmente realizada com ferramentas como DESeq2, que modela contagens de RNA-seq por distribuição binomial negativa, estima fatores de tamanho, calcula dispersões e produz estatísticas como log2FC, valor-p e valor-p ajustado [3].

Embora métodos estatísticos continuem centrais, abordagens de aprendizado de máquina têm sido exploradas para tarefas de classificação envolvendo expressão gênica, incluindo seleção de características, classificação de cânceres e classificação de genes diferencialmente expressos [4, 5, 6]. Nesse contexto, os dados costumam ser representados em tabelas de alta dimensionalidade ou em conjuntos de características derivadas de análises estatísticas. Modelos baseados em árvores, como Random Forest e XGBoost, seguem competitivos em dados tabulares, especialmente em conjuntos pequenos ou médios, e estabelecem uma referência importante para avaliar modelos neurais [7, 8, 9].

Uma alternativa recente consiste em transformar dados tabulares em imagens, tornando-os compatíveis com CNNs. Esses conversores table-to-image (T2I) buscam organizar características em uma matriz bidimensional, preservando relações de vizinhança ou criando estruturas espaciais artificiais que possam ser exploradas por filtros convolucionais [10, 11, 12, 13]. Entre esses métodos, DeepInsight projeta características em duas dimensões por técnicas como t-SNE, NCTD aplica transformações geométricas determinísticas para criar matrizes pseudo-espaciais, e HACNet aprende uma representação visual associada a templates e mecanismos de atenção [10, 14, 13].

Este trabalho propõe e organiza um pipeline comparativo para avaliar esses três conversores na classificação de genes como regulados positivamente, regulados negativamente ou não diferencialmente expressos. A investigação é baseada em dados públicos de RNA-seq dos projetos TCGA-LUAD, TCGA-KIRC e TCGA-PRAD, com construção de tabelas gene-cêntricas derivadas de DESeq2, conversão dessas tabelas em imagens, treinamento de CNNs baseadas em ResNet18, comparação com modelos tradicionais de aprendizado de máquina e análise de enriquecimento funcional como validação biológica.

2 Trabalhos Relacionados

A aplicação de aprendizado de máquina a dados de expressão gênica tem sido motivada pela possibilidade de identificar padrões de regulação e perfis moleculares associados a doenças. Revisões recentes descrevem o uso de métodos supervisionados para classificação de câncer a partir de dados de expressão, bem como a crescente incorporação de aprendizado profundo em problemas de transcriptômica [4]. Em tarefas mais próximas à classificação de DEGs, DEGnext utilizou CNNs e transferência de aprendizado para classificar genes a partir de matrizes de expressão, enquanto TabDEG propôs uma estrutura de extração de características e aprendizado profundo para distinguir genes diferencialmente expressos [5, 6].

Apesar desses avanços, a classificação de DEGs por CNNs ainda é pouco explorada quando comparada a tarefas de classificação de amostras ou tumores. Além disso, trabalhos anteriores frequentemente utilizam representações matriciais simples ou redes densas, sem avaliar de forma sistemática diferentes conversores T2I. Essa lacuna é relevante porque a utilidade de uma CNN depende fortemente da estrutura espacial da entrada. Se a disposição dos pixels não representar relações informativas, a convolução pode operar sobre vizinhanças artificiais pouco relacionadas ao problema biológico.

DeepInsight é um dos primeiros métodos T2I aplicados a dados não imagéticos e a dados ômicos. O método reduz a dimensionalidade das características para um espaço bidimensional, posiciona cada variável em uma grade e preenche os pixels com os valores das características de cada observação [10]. Sua vantagem é tentar preservar relações de similaridade entre características, mas sua estabilidade pode depender da técnica de projeção, da parametrização e do tamanho da imagem. Em especial, métodos como t-SNE podem ser sensíveis ao subconjunto de dados e à escolha de perplexidade [15].

O NCTD, por sua vez, busca reduzir a complexidade da projeção dimensional ao transformar diretamente cada vetor de características em uma matriz de pixels. Após normalização Min-Max, o vetor é replicado para formar uma matriz $N \times N$, suas linhas sofrem deslocamentos progressivos e a matriz é expandida para $2N \times 2N$ [13]. Trata-se de uma estratégia simples e determinística, adequada a conjuntos com poucas características, embora suas relações espaciais sejam induzidas matematicamente e não necessariamente reflitam proximidade biológica real.

HACNet representa uma abordagem distinta porque integra conversão T2I e classificação em um

treinamento ponta-a-ponta. O método usa atenção para mapear características tabulares em pixels e combina a perda de classificação com uma penalização de semelhança entre as imagens geradas e templates associados às classes [14]. Essa formulação torna o método interessante para discussões de interpretabilidade, pois a imagem final pode ser relacionada ao template e, potencialmente, às características que receberam maior atenção.

3 Materiais e Métodos

A Figura 1 apresenta a visão geral do pipeline experimental proposto.




Figura 1: Pipeline experimental. ① Aquisição de dados RNA-seq do TCGA; ② Análise de expressão diferencial com DESeq2; ③ Construção da tabela gene-cêntrica com 12 features e rotulagem; ④ Conversão T2I por três métodos (esquerda) e modelos ML tabulares como baseline (direita); ⑤ Classificação por ResNet-18; ⑥ Avaliação comparativa.

3.1 Obtenção dos dados e construção das tabelas

Foram utilizados dados públicos de RNA-seq dos projetos TCGA-LUAD, TCGA-KIRC e TCGA-PRAD. As matrizes de contagem foram obtidas em R por meio do pacote TCGAbiolinks, consultando o Genomic Data Commons na categoria Transcriptome Profiling, tipo Gene Expression Quantification e workflow STAR - Counts [16, 17]. Após o download, os dados foram preparados com GDCprepare e a matriz de contagens brutas foi extraída do ensaio *unstranded*.

As amostras foram filtradas de acordo com os códigos presentes nos identificadores TCGA. Foram mantidas amostras tumorais primárias, identificadas pelo código 01, e amostras normais sólidas, identificadas pelo código 11. Em seguida, foi criado um fator experimental com os níveis Tumor e Normal. Antes da análise estatística, genes de baixa expressão foram filtrados com base em contagens por milhão

calculadas pelo edgeR, mantendo apenas genes com CPM maior que 1 em pelo menos 10% das amostras do respectivo projeto [18].

A análise de expressão diferencial foi realizada com DESeq2 a partir de um objeto DESeqDataSet construído com desenho experimental $\sim condition$. A função DESeq foi utilizada para estimar fatores de tamanho, dispersões e ajustar os modelos gene a gene. Os resultados foram extraídos com `results`, obtendo $\log_2FC$, valor-p e valor-p ajustado. Genes com valores ausentes decorrentes de filtragem independente ou da distância de Cook foram removidos antes da construção final das tabelas.

Os rótulos foram definidos a partir de limiares estatísticos: genes com $padj < 0,05$ e $\log_2FC \geq 1$ foram classificados como regulados positivamente; genes com $padj < 0,05$ e $\log_2FC \leq -1$ foram classificados como regulados negativamente; os demais foram considerados não diferencialmente expressos. Cada linha da tabela final correspondeu a um gene. As 12 características utilizadas foram $\log_2FC$, média de expressão em tumor, média de expressão em normal, dispersão, variância, porcentagem de amostras expressas, valor-p, $padj$, baseMean, $\log_2FC$ absoluto, razão de expressão e coeficiente de variação.

Tabela 1: Estrutura dos conjuntos de dados gene-cêntricos utilizados.

Projeto	Genes	Features	DR	UR	ND
TCGA-LUAD	19.304	12	1.904	3.623	13.777
TCGA-KIRC	18.603	12	1.846	3.899	12.858
TCGA-PRAD	17.533	12	1.363	1.159	15.011

3.2 Conversão de tabelas em imagens

As tabelas finais foram convertidas em imagens por DeepInsight, NCTD e HACNet. Para DeepInsight, foi utilizada a biblioteca pyDeepInsight com t-SNE em duas dimensões, perplexidade 3, discretização por bins e resolução final de 32×32 pixels. A escolha de uma baixa perplexidade foi motivada pelo pequeno número de características, enquanto a resolução de 1024 pixels buscou reduzir colisões entre variáveis mapeadas para a mesma posição.

O NCTD foi implementado em Python a partir da metodologia original. Após normalização Min-Max, cada vetor foi convertido em intensidades de 0 a 255, replicado e deslocado progressivamente para formar uma matriz $N \times N$ e expandido para uma imagem $2N \times 2N$. Como as tabelas continham 12 características, as imagens geradas pelo NCTD apresentaram 24×24 pixels.

Para HACNet, a conversão ocorreu de forma integrada ao treinamento do próprio método. O repositório original foi adaptado para receber os conjuntos TCGA e os folds gerados previamente. O procedimento utilizou os ciclos de treinamento e retreinamento previstos pelo HACNet e gerou imagens finais de 100×100 pixels para cada gene.

Para garantir reprodutibilidade, os dados foram divididos em cinco folds estratificados com semente aleatória fixa igual a 42. As atribuições de genes aos folds foram salvas em arquivos CSV e reutilizadas na conversão e na classificação.

Tabela 2: Resumo metodológico dos conversores T2I avaliados.

Conversor	Estratégia	Resolução	Observação
DeepInsight	Projeção t-SNE + grade	32×32	Sensível à projeção
NCTD	Normalização + rotação $2N \times 2N$	24×24	Determinístico
HACNet	Atenção + templates	100×100	Maior interpretabilidade

3.3 Classificação com CNN baseada em ResNet18

A classificação das imagens foi realizada com PyTorch utilizando-se ResNet18 como critic (avaliador) sem pesos pré-treinados [19]. A primeira convolução foi modificada para receber uma única dimensão de canal de forma a ser compatível com as imagens geradas em tons cinza e a camada final foi substituída por uma camada linear com três saídas. A otimização utilizou entropia cruzada, AdamW com taxa de aprendizado 10^{-3} , decaimento de peso 10^{-4} , lote de 64 amostras e 50 épocas. Um escalonador CosineAnnealingLR ajustou a taxa de aprendizado. O melhor checkpoint foi escolhido pela acurácia de validação.

As métricas calculadas foram acurácia, precisão macro, revocação macro, F1-score macro e ROC AUC multiclasse (one-vs-rest).

3.4 Modelos tradicionais de aprendizado de máquina

Como referência, foram avaliados modelos tradicionais diretamente sobre as 12 características tabulares: regressão logística multinomial, XGBoost, Random Forest, SVM (kernel RBF) e Naive Bayes gaussiano. Todos foram avaliados com as mesmas divisões estratificadas de cinco folds usadas para as CNNs. Para lidar com desbalanceamento de classes, foram calculados pesos de amostra balanceados. Os principais hiperparâmetros foram: XGBoost com 300 estimadores, $\text{lr}=0,05$ e $\text{max_depth}=5$; Random Forest com 300 árvores; SVM com $C = 2,0$ e $\gamma = \text{scale}$; regressão logística com $\text{max_iter}=2000$ [7, 8, 20].

3.5 Enriquecimento funcional e validação biológica

A validação biológica foi realizada por enriquecimento funcional de processos biológicos do Gene Ontology. O enriquecimento foi executado com g:Profiler para *Homo sapiens*, restringindo a fonte a GO:BP e usando correção FDR com limiar de 0,05 [21].

4 Resultados e Discussão

Esta seção apresenta a análise comparativa entre os conversores T2I aplicados à classificação de DEGs. A arquitetura base utilizada foi a ResNet-18 modificada para aceitar imagens em tons de cinza (1 canal).

4.1 Comparação entre os Conversores T2I

O desempenho dos métodos foi avaliado sob as mesmas condições experimentais, com validação cruzada estratificada em cinco folds. A Tabela 3 sumariza os resultados. A natureza da transformação influenciou diretamente a capacidade da CNN em extrair padrões espaciais dos dados transcriptômicos.

Tabela 3: Desempenho médio (5-fold CV) dos conversores T2I com ResNet-18.

Conversor	Dataset	Accuracy	Precision	Recall	F1-Score	ROC-AUC
HACNet	KIRC	0.9988	0.9989	0.9980	0.9984	1.0000
HACNet	LUAD	0.9963	0.9967	0.9925	0.9946	1.0000
HACNet	PRAD	0.9952	0.9885	0.9874	0.9880	0.9999
DeepInsight	KIRC	0.9899	0.9907	0.9799	0.9850	0.9987
DeepInsight	LUAD	0.9963	0.9970	0.9932	0.9950	0.9997
DeepInsight	PRAD	0.9957	0.9981	0.9791	0.9882	0.9998
NCTD	KIRC	0.9956	0.9914	0.9950	0.9931	1.0000
NCTD	LUAD	0.9902	0.9938	0.9775	0.9851	0.9973
NCTD	PRAD	0.9635	0.9329	0.9214	0.9099	0.9586

O HACNet obteve o melhor F1-Score em KIRC (0.9984), enquanto DeepInsight liderou em LUAD (0.9950) e PRAD (0.9882). O NCTD apresentou desempenho competitivo em KIRC e LUAD, porém sofreu queda significativa em PRAD ($F1=0.9099$), indicando sensibilidade ao alto desbalanceamento deste dataset (85.6% classe NoDifference).

4.2 Comparação com Modelos Tradicionais

Esta seção estabelece o desempenho de referência por meio de classificadores de machine learning treinados diretamente sobre as tabelas de características gênicas.

Random Forest alcançou resultados perfeitos ou quase-perfeitos em todos os datasets ($F1=0.9997-1.0000$), seguido por XGBoost ($F1 \geq 0.9980$). Naive Bayes falhou significativamente ($F1 < 0.72$), evidenciando que a suposição de independência entre features não se sustenta para as 12 características gênicas utilizadas. A Figura 2 apresenta o ranking consolidado.

Tabela 4: Desempenho dos classificadores de ML em dados tabulares (5-fold CV).

Dataset	Modelo	Accuracy	Precision	Recall	F1-Score	Tempo(s)
KIRC	Random Forest	0.9998	0.9995	0.9998	0.9997	4.25
KIRC	XGBoost	0.9987	0.9979	0.9985	0.9982	21.45
KIRC	Logistic Reg.	0.9877	0.9699	0.9941	0.9815	0.39
KIRC	SVM	0.9779	0.9499	0.9880	0.9678	10.49
KIRC	Naive Bayes	0.6085	0.6378	0.8075	0.6204	0.15
LUAD	Random Forest	0.9999	0.9998	1.0000	0.9999	4.25
LUAD	XGBoost	0.9987	0.9982	0.9984	0.9983	7.55
LUAD	Logistic Reg.	0.9860	0.9651	0.9934	0.9787	0.32
LUAD	SVM	0.9755	0.9432	0.9875	0.9640	11.42
LUAD	Naive Bayes	0.7393	0.6784	0.8717	0.7133	0.15
PRAD	Random Forest	1.0000	1.0000	1.0000	1.0000	4.53
PRAD	XGBoost	0.9992	0.9978	0.9982	0.9980	8.87
PRAD	Logistic Reg.	0.9868	0.9438	0.9948	0.9681	0.29
PRAD	SVM	0.9812	0.9245	0.9906	0.9554	8.17
PRAD	Naive Bayes	0.6452	0.5436	0.8576	0.5593	0.13




Figura 2: Ranking geral por F1-Score de todos os métodos (CNN + ML) segmentados por dataset.

4.3 Análise das Matrizes de Confusão

A inspeção das matrizes de confusão revelou padrões de erro distintos entre as abordagens. O Random Forest apresentou erros praticamente inexistentes: em PRAD, obteve 0 erros em todos os 5 folds; em KIRC, apenas 4 amostras foram mal classificadas em ~ 18.600 ; em LUAD, apenas 1 erro em ~ 19.300 . Os erros do XGBoost (~ 24 em KIRC, ~ 25 em LUAD) concentraram-se na classe NoDifference sendo confundida com DR ou UR, sugerindo que genes próximos ao limiar de significância estatística geram maior incerteza.

Para o HACNet (melhor CNN), o padrão de erros foi similar ao dos modelos tabulares, com taxa de confusão inferior a 0.2% por classe. O NCTD em PRAD apresentou maior confusão entre as classes minoritárias (UR e DR) e a classe majoritária (ND), refletindo a dificuldade do mapeamento determinístico em preservar a separabilidade biológica sob forte desbalanceamento.




Figura 3: Matrizes de confusão — comparação entre Random Forest (melhor tabular) e HACNet (melhor CNN).

4.4 Estabilidade entre os Folds

A robustez dos modelos foi avaliada pela variabilidade entre os cinco folds da validação cruzada. Os conversores HACNet e DeepInsight demonstraram alta estabilidade, com variação de F1-Score inferior a 0.005 entre folds. O NCTD apresentou maior variabilidade em PRAD (ROC-AUC=0.9586, comparado a ≥ 0.9973 nos demais cenários), indicando sensibilidade à partição dos dados quando o desbalanceamento é extremo. Os modelos tabulares (RF e XGBoost) foram os mais estáveis, com desvio-padrão negligenciável.




Figura 4: Boxplot de variabilidade entre folds para os conversores T2I.

4.5 Comparação entre os Conjuntos de Dados (TCGA)

Ao segmentar a análise pelos projetos TCGA, verificou-se que o desempenho dos conversores é influenciado pelo perfil transcriptômico de cada tumor:

- **KIRC** (18.603 genes, 69.3% ND): HACNet obteve o melhor F1 entre CNNs (0.9984), próximo ao Random Forest (0.9997).
- **LUAD** (19.304 genes, 71.3% ND): DeepInsight liderou entre CNNs (F1=0.9950), superando marginalmente o HACNet (0.9946).
- **PRAD** (17.533 genes, 85.6% ND): o desbalanceamento extremo penalizou o NCTD (F1=0.9099), enquanto DeepInsight (0.9882) e HACNet (0.9880) mantiveram desempenho elevado.

A proporção da classe NoDifference (69.3%→71.3%→85.6%) correlacionou-se inversamente com o desempenho do NCTD, sugerindo que sua transformação determinística não compensa adequadamente o viés de classe.

4.6 Discussão

Os resultados demonstram que modelos tabulares (Random Forest e XGBoost) superaram consistentemente as abordagens CNN+T2I em métricas preditivas, com Random Forest atingindo F1=0.9997–1.0000. Isto é condizente com trabalhos anteriores que atestaram a eficácia de métodos ensemble baseados em árvores em dados tabulares, e que a aplicação de conversores em imagens com CNNs nestes dados não necessariamente consegue criar informações espaciais que deem vantagens significativas em relação a abordagens anteriores.

Contudo, os desempenhos utilizando as diferentes combinações de conversor e dataset não ficaram muito abaixo, uma vez que os F1-scores médios obtidos em LUAD, PRAD e KIRC foram quase perfeitos para praticamente todas as execuções, diferindo em algumas unidades nas classificações corretas em relação às abordagens de Random Forest, como é possível ver nas matrizes de confusão da figura 3. O padrão que se observa para a aplicação do HACNet também é verificado em todas as outras execuções, com exceção do caso NCTD-PRAD, onde as medidas de performance ficaram muito abaixo, especulativamente, em grande medida devido ao forte desbalanceamento de classes presente nesse dataset, ao qual o NCTD seria sensível. Isso evidencia a capacidade do uso geral de pipelines T2I para classificação de dados tabulares como ferramenta auxiliar a métodos como Random Forest e XGBoost, e não como algo que os substitua, ainda mais se forem observadas as limitações e vantagens de cada conversor.

Entre os conversores, HACNet (F1 médio=0.9937) e DeepInsight (F1 médio=0.9894) obtiveram resultados competitivos, seguidos pelo NCTD (F1 médio=0.9294), que teve sua performance prejudicada pela execução NCTD-PRAD. A correção da implementação do DeepInsight (global fit + resolução adequada) foi determinante — a versão inicial com grid 4×4 produzia F1<0.28, demonstrando extrema sensibilidade à configuração.

A escolha metodológica envolve um equilíbrio entre fidelidade topológica, custo computacional e interpretabilidade. O DeepInsight preserva distâncias biológicas via projeção t-SNE, apresentando robustez quando corretamente configurado, porém com sensibilidade à resolução da imagem de saída. O NCTD, por sua natureza determinística, oferece solução eficiente e reprodutível, embora com viés de vizinhança artificial que se agrava sob forte desbalanceamento. O HACNet, com transfer learning do critic ResNet-18 e imagens 100×100, possibilita maior preservação de informação e interpretabilidade via Grad-CAM, permitindo análise visual dos fatores de decisão do modelo.

Embora as CNNs não tenham superado os modelos tabulares em desempenho preditivo puro, o principal valor dos conversores T2I neste contexto reside na possibilidade de aplicar técnicas de explicabilidade visual (Grad-CAM, saliency maps) para identificar quais grupos de features gênicas mais influenciam a classificação. A conversão de dados tabulares em imagens atua como engenharia de features que permite explorar a localidade espacial, consolidando os conversores T2I como alternativa complementar aos pipelines tradicionais — especialmente em cenários onde a interpretabilidade visual do modelo é desejável para a descoberta de assinaturas gênicas.

A análise de enriquecimento funcional forneceu uma camada adicional de validação biológica. Nos conjuntos KIRC e LUAD, os genes regulados positivamente apresentaram termos ligados à resposta imune adaptativa. Em PRAD, genes regulados positivamente apresentaram enriquecimento relacionado a checkpoint mitótico e segregação cromossômica. Esses padrões confirmam que os rótulos definidos por DESeq2 capturam grupos biologicamente interpretáveis.

Tabela 5: Principais resultados de enriquecimento GO:BP.

Projeto	Classe	Termos signif.	Termo mais significativo
KIRC	UR	550	adaptive immune response
KIRC	DR	644	carboxylic acid metabolic process
LUAD	UR	113	adaptive immune response
LUAD	DR	1.064	multicellular organismal process
PRAD	UR	49	mitotic spindle assembly checkpoint
PRAD	DR	953	multicellular organismal process

5 Conclusão

Este trabalho organizou um pipeline comparativo para investigar a conversão de tabelas gene-cêntricas de RNA-seq em imagens e sua posterior classificação por CNNs. A avaliação integrou análise de expressão diferencial com DESeq2, conversão por DeepInsight, NCTD e HACNet, treinamento de ResNet-18, comparação com modelos tradicionais de aprendizado de máquina e enriquecimento funcional por GO:BP.

Os modelos tradicionais, em particular Random Forest ($F1=0.9997-1.0000$) e XGBoost ($F1=0.9980-0.9983$), superaram consistentemente as abordagens baseadas em CNN com conversão T2I. Entre os conversores, HACNet ($F1=0.9880-0.9984$) e DeepInsight ($F1=0.9850-0.9950$) obtiveram os melhores resultados, seguidos por NCTD ($F1=0.9099-0.9931$). A implementação correta dos conversores mostrou-se crítica: a versão inicial do DeepInsight com resolução inadequada produzia $F1 < 0.28$, enquanto a versão corrigida alcançou $F1 \geq 0.98$.

Os resultados de enriquecimento funcional confirmaram que os rótulos definidos por DESeq2 capturam grupos biologicamente interpretáveis. Embora as CNNs não superem os modelos tabulares em desempenho preditivo puro, os resultados em geral chegam perto, e os conversores T2I oferecem uma via para aplicação de técnicas de explicabilidade visual (Grad-CAM) que podem complementar pipelines tradicionais na descoberta de assinaturas gênicas.

Disponibilidade de código e dados

Os dados de RNA-seq utilizados são públicos e provenientes do TCGA/GDC. As tabelas gene-cêntricas e os scripts foram organizados para permitir reexecução e auditoria do pipeline experimental. Scripts principais: `Conversion_NCTD_DeepInsight.py`; `classification_CNN.py`; `traditional_MLs_analysis.py`; `enrichment_analysis.py`. Estes e outros estão disponíveis no repositório público disponível em: https://github.com/Lord-Hubner/Converters_Analysis_.

Referências

- [1] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *Nature*, 521(7553):436–444, 2015.
- [2] Daniele Rosati et al. Differential gene expression analysis pipelines and bioinformatic tools for the identification of specific biomarkers: A review. *Computational and Structural Biotechnology Journal*, 23:1154–1168, 2024.
- [3] Michael I. Love, Wolfgang Huber, and Simon Anders. Moderated estimation of fold change and dispersion for RNA-seq data with DESeq2. *Genome Biology*, 15:550, 2014.
- [4] Fadi Alharbi and Aleksandar Vakanski. Machine learning methods for cancer classification using gene expression data: A review. *Bioengineering*, 10(2):173, 2023.
- [5] Tulika Kakati et al. DEGnext: classification of differentially expressed genes from RNA-seq data using a convolutional neural network with transfer learning. *BMC Bioinformatics*, 23:17, 2022.
- [6] Shengjie Feng et al. TabDEG: Classifying differentially expressed genes from RNA-seq data based on feature extraction and deep learning framework. *PLOS ONE*, 19(7):e0305857, 2024.
- [7] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.

- [8] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- [9] Léo Grinsztajn, Edouard Oyallon, and Gaël Varoquaux. Why do tree-based models still outperform deep learning on tabular data? *arXiv preprint arXiv:2207.08815*, 2022.
- [10] Alok Sharma et al. DeepInsight: a methodology to transform a non-image data to an image for convolution neural network architecture. *Scientific Reports*, 9:11399, 2019.
- [11] Omid Bazgir et al. Representation of features as images with neighborhood dependencies for compatibility with convolutional neural networks. *Nature Communications*, 11:4391, 2020.
- [12] Luiz Matos Neto, Silvio R. da Silva Neto, and Patricia T. Endo. A comparative analysis of converters of tabular data into image for the classification of arboviruses using convolutional neural networks. *PLOS ONE*, 18(12):e0295598, 2023.
- [13] Hanan A. Alenizy and Jawad Berri. Transforming tabular data into images via enhanced spatial relationships for CNN processing. *Scientific Reports*, 15:17004, 2025.
- [14] Teppei Matsuda et al. HACNet: End-to-end learning of interpretable table-to-image converter and convolutional neural network. *Knowledge-Based Systems*, 284:111293, 2024.
- [15] Laurens van der Maaten and Geoffrey Hinton. Visualizing data using t-SNE. *Journal of Machine Learning Research*, 9:2579–2605, 2008.
- [16] Antonio Colaprico et al. TCGAbiolinks: an R/Bioconductor package for integrative analysis of TCGA data. *Nucleic Acids Research*, 44(8):e71, 2016.
- [17] Robert L. Grossman et al. Toward a shared vision for cancer genomic data. *New England Journal of Medicine*, 375(12):1109–1112, 2016.
- [18] Mark D. Robinson, Davis J. McCarthy, and Gordon K. Smyth. edgeR: a Bioconductor package for differential expression analysis of digital gene expression data. *Bioinformatics*, 26(1):139–140, 2010.
- [19] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. *arXiv preprint arXiv:1512.03385*, 2015.
- [20] Fabian Pedregosa et al. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [21] Uku Raudvere et al. g:Profiler: a web server for functional enrichment analysis and conversions of gene lists. *Nucleic Acids Research*, 47:W191–W198, 2019.